

19 MAYIS 2025



İST366_1_2425B
REGRESYON ÇÖZÜMLEMESİ ÖDEVİ

TANER YEŞİLAY
2220329090

Giriş

Bu çalışmada, belirli bir işletmenin aylık kar performansını etkileyen faktörler çoklu doğrusal regresyon yöntemiyle analiz edilmiştir. Verilen veri setinde yer alan değişkenler göz önünde bulundurularak, işletme karlılığına etki edebilecek bir senaryo geliştirilmiş; bu senaryo çerçevesinde hem teorik hem de uygulamalı istatistiksel analizler yapılarak en uygun regresyon modeli oluşturulmaya çalışılmıştır.

Çalışmada bağımlı değişken olarak işletmenin **aylık kar miktarı (y)** alınmıştır. Bağımsız değişkenler ise **satış hacmi (x1)**, ortalama **satış fiyatı (x2)**, **birim üretim maliyeti (x3)** ve uygulanan **pazarlama stratejisi (x4, 3 düzeyli kategorik değişken)** olarak tanımlanmıştır. Pazarlama stratejisi değişkeni “Standart”, “Hedefli” ve “Yaratıcı” olmak üzere üç farklı yaklaşımı içermektedir.

Analiz sürecine başlamadan önce, veri setinin tanımlayıcı istatistikleri elde edilmiş; değişkenlerin merkezi eğilim ve yayılım ölçüleri incelenerek başlangıç düzeyinde bir değerlendirme yapılmıştır. Daha sonra, çoklu regresyon modelinin kurulabilmesi için gerekli varsayımlardan olan doğrusallık ve normallik kontrolleri yapılmış, gerekli dönüşümler uygulanmıştır. Elde edilen model üzerinden artık incelemesi gerçekleştirilmiştir.

Modelin geçerliliği sağlandıktan sonra, regresyon kestirim denklemi, standart hataları ile birlikte ifade edilmiş; modelin genel anlamlılığı F-testi ile sınanmıştır. Ayrıca, her bir regresyon katsayısının bireysel anlamlılığı da t-testi yardımıyla kontrol edilerek yorumlanmıştır. Modelin açıklama gücü, belirtme katsayısı (R^2) ve düzeltilmiş belirtme katsayısı (Adjusted R^2) üzerinden değerlendirilmiştir. Katsayılar için %99 güven aralıkları hesaplanmış ve bu aralıklar bağlamında yorumlar sunulmuştur.

Ayrıca modelde yer alan hata terimlerinin özellikleri de detaylı biçimde incelenmiştir. Artıklar üzerinden değişen varyanslılık, öz ilişki (otokorelasyon) ve çoklu bağlantı (multikolinerite) sorunları hem grafiksel hem de testsel yöntemlerle analiz edilmiştir. Bu sorunlardan herhangi biri tespit edildiğinde gerekli düzeltmeler yapılmıştır.

İlgili model üzerinden, veri kümesinde yer alan bir gözlem için uyum kestirimi (fitted value) ve veri kümesinde bulunmayan bir gözlem için ön kestirim (prediction) yapılmış; bu tahminler için %95 güven düzeyinde güven aralıkları hesaplanmış ve yorumlanmıştır.

Son olarak, değişken seçimi yöntemleri (ileriye doğru seçim, geriye doğru eleme, ve adım adım seçim) kullanılarak en iyi model belirlenmeye çalışılmıştır. Tüm yöntemlerden elde edilen sonuçlar karşılaştırılarak en uygun model önerilmiştir. Ayrıca Ridge Regresyon tekniği uygulanarak, ridge izi grafiği yorumlanmış ve çoklu bağlantı problemi için alternatif bir çözüm sunulmuştur.

Bu çalışma sayesinde, kar üzerinde etkili olan değişkenler net bir şekilde ortaya konmuş; işletmelerin karlılıklarını artırmaları için stratejik önlemler alınmasına katkı sağlanmıştır.

1. Veri Seti ve Değişken Tanımı

R da veriyi çekmek ve değişkenlerin değişim aralıklarına bakmak için oluşturduğum kod:

```
setwd("C:/Users/taner/OneDrive/Masa\u00fcstü/projeler/regresyon/odev")
data <- read.table("file 30_2220329090_TanerYesilay.txt", header = TRUE)

print(paste("kayıp gözlem var mı?", any(is.na(data))))

## [1] "kayıp gözlem var mı? FALSE"

max_values <- apply(data[, !names(data) %in% "x4"], 2, max, na.rm = TRUE)
min_values <- apply(data[, !names(data) %in% "x4"], 2, min, na.rm = TRUE)

min_max_values <- rbind(Minimum = min_values, Maximum = max_values)
print(min_max_values)

##           y           x1           x2           x3
## Minimum 33.12014 3.434418 0.680905 1.770873
## Maximum 144.33616 8.797344 5.945080 6.766252
```

1. Bağımsız değişken (y):

- **Anlam** : Bir işletmenin aylık kar miktarı (TL cinsinden).
- **Minimum** : 33.12014 TL
- **Maksimum** : 144.33616 TL

2. Bağımlı değişken:

- **x1** : Satış hacmi (birim başına satılan ürün adedi).
 - **Minimum**: 3.34418
 - **Maksimum**: 8.797344
 - **Anlam** : Bu değişken, işletme tarafından satılan ürünlerin toplam miktarını temsil eder.
- **x2** : Ortalama satış fiyatı (birim başına fiyat).
 - **Minimum**: 0.680905
 - **Maksimum**: 5.945080
 - **Anlam** : Bu değişken, birim başına ortalamaya döndürülen satış fiyatını ifade eder.
- **x3** : Üretim maliyeti (birim başına maliyet).
 - **Minimum**: 1.770873
 - **Maksimum**: 6.766252
 - **Anlam** : Bu değişken, birim başına ortalamaya döndürülen üretim maliyetini temsil eder.

- **x4** : Pazarlama stratejisi (faktör değişken, 3 düzeyli)
 - **Düzy 1:** Standart pazarlama (kılavuz değişken)
 - **Düzy 2:** Hedefli pazarlama
 - **Düzy 3:** Yaratıcı pazarlama
 - **Anlam** : Bu değişken, işletmenin uyguladığı pazarlama stratejisini temsil eder. Her düzey, farklı pazarlama yaklaşımlarını içerir ve bu stratejiler kar üzerinde farklı etkiler oluşturabilir

2. Değişkenlerinize ait tanımlayıcı istatistikler

```
#Sayısal değişkenlerin özet istatistikleri
summary(data[, !names(data) %in% "x4"])
```

##	y	x1	x2	x3
##	Min. : 33.12	Min. : 3.434	Min. : 0.6809	Min. : 1.771
##	1st Qu.: 58.50	1st Qu.: 5.442	1st Qu.: 2.3342	1st Qu.: 3.145
##	Median : 66.96	Median : 5.973	Median : 2.8894	Median : 3.802
##	Mean : 67.13	Mean : 6.032	Mean : 2.9435	Mean : 3.918
##	3rd Qu.: 75.21	3rd Qu.: 6.734	3rd Qu.: 3.6741	3rd Qu.: 4.627
##	Max. : 144.34	Max. : 8.797	Max. : 5.9451	Max. : 6.766

Bağımlı Değişken: y (Aylık Kar Miktarı)

- Ortalama : 67.13 TL
- Medyan : 66.96 TL
→ Ortalama ile medyan arasındaki fark çok küçük olduğu için dağılımın simetrik veya hafif çarpık olduğu söylenebilir.
- Minimum – Maksimum Aralığı : 33.12 TL – 144.34 TL
→ Gözlemler genel olarak geniş bir aralıkta yayılmıştır, bu da işletmenin kar performansında zaman içinde önemli değişiklikler olduğunu gösterir.
- Çeyrekler Arası Yayılım (IQR) : 58.50 – 75.21 TL
→ Verilerin orta %50'si nispeten dar bir aralıkta toplanmıştır.

Bağımsız Değişken: x1 (Satış Hacmi - Birim Sayısı)

- Ortalama : 6.03 birim
- Medyan : 5.97 birim
→ Ortalama ve medyan değerleri oldukça yakın, bu da satılan ürün sayısının dengeli dağıldığını gösterir.
- Minimum – Maksimum Aralığı : 3.43 – 8.80 birim
→ Satış hacmindeki değişim sınırlı görünmektedir; ani sıçramalar yok.
- Çeyrekler Arası Yayılım (IQR) : 5.44 – 6.73 birim
→ Verilerin çoğu merkeze yakın yoğunlaşmış.

Bağımsız Değişken: x2 (Ortalama Satış Fiyatı - TL cinsinden)

- Ortalama : 2.94 TL

- Medyan : 2.89 TL
→ Dağılımın hafif sağa çarpık olabileceğini düşündürür (ortalama medyandan büyük).
- Minimum – Maksimum Aralığı : 0.68 – 5.95 TL
→ Satış fiyatlarında ciddi farklılıklar bulunduğu anlaşılıyor. Bu durum, ürün çeşitliliği veya zam politikalarıyla açıklanabilir.
- Çeyrekler Arası Yayılım (IQR) : 2.33 – 3.67 TL
→ Merkezi %50'lik dilimde belirli bir sabitlik gözleniyor.


Bağımsız Değişken: x3 (Birim Başına Üretim Maliyeti - TL cinsinden)

- Ortalama : 3.92 TL
- Medyan : 3.80 TL
→ Ortalamanın medyandan yüksek olması dağılımın hafif sağa çarpık olduğunu gösterir.
- Minimum – Maksimum Aralığı : 1.77 – 6.77 TL
→ Maliyetlerdeki değişkenlik fazla görünüyor. Bu durum üretim süreçlerinin tutarlılığı açısından dikkat edilmesi gereken bir husus olabilir.
- Çeyrekler Arası Yayılım (IQR) : 3.15 – 4.63 TL
→ Merkezi değerler daha dengeli dağılmış.

#x4 değişkeni için frekans dağılımı

```
counts <- table(data$x4)
labels <- paste0(names(counts), "\n(", counts, ")")
pie(counts,
    labels = labels,
    main = "x4 Değişkeninin Dağılımı",
    col = c("lightblue", "lightgreen", "lightcoral"),
    cex = 0.8)
```

x4 Değişkeninin Dağılımı



#x4 değişkeni Yüzdelik dağılım (yuvarlanmış hali)

```
print(round(prop.table(table(data$x4)) * 100, 2))
```

```
##
##      1      2      3
## 34.21 34.21 31.58
```

Bağımsız Değişken: Pazarlama stratejisi (kategorik değişken, 3 düzeyli)


- Düzey 1 (Standart Pazarlama) : 65 gözlem (%34.21)
- Düzey 2 (Hedefli Pazarlama) : 65 gözlem (%34.21)
- Düzey 3 (Yaratıcı Pazarlama) : 60 gözlem (% 31.58)

Şirketin Standart Pazarlama ve Hedefli Pazarlama stratejilerini daha sık kullandığı, Yaratıcı Pazarlama ise daha az tercih ettiği gözlemlenmektedir. Bu, şirketin daha konservatif bir pazarlama yaklaşımını izlediğini veya yaratıcı stratejileri daha dikkatli bir şekilde uyguladığını düşündürebiliriz.

3. Regresyon Modeli İçin Ön İnceleme: Doğrusallık ve Normallik Varsayımları

3.1 Normallik kontrolü

```
qqnorm(data$y)
qqline(data$y)
```



Q-Q plot incelendiğinde, noktalarının büyük çoğunluğunun 45 derecelik doğru etrafında toplandığı görülmektedir. Bu durum, verinin normal dağılıma uygun olduğunu düşündürmektedir. Ancak, görsel değerlendirme yeterli olmayabilir, bu yüzden istatistiksel bir test ile doğrulama yapmak önemlidir.

Gözlem sayısının 50'den fazla olması sebebiyle, daha hassas bir değerlendirme için Lilliefors düzeltilmeli Kolmogorov-Smirnov testi uygulanmıştır.

```
#lillie düzeltmeli kolmogro-smirnov testi
library(nortest) #gerekli kütüphaneyi yükleyelim
lillie_test_result <- lillie.test(data$y)
print(lillie_test_result) #H0 red edilemez veri normal dağılıyr


##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  data$y
## D = 0.063641, p-value = 0.05865
```

H_0 = işletmenin aylık kar miktarı (y) dağılımı ile normal dağılım arasında **fark yoktur**

H_1 = işletmenin aylık kar miktarı (y) dağılımı ile normal dağılım arasında **fark vardır**

p-değeri 0.05865 , %95 güven düzeyinde H_0 red edilemez. Bu durumda normal dağılım varsayımını kabul edebiliriz.

```
# bağımlı değişkenin dağılımı
hist(data$y,
      main = "bağımlı değişkenin Histogramı",
      xlab = "y",
      ylab = "Frekans",
      col = "skyblue",
      border = "white",
      breaks = 30)
```



Veri dağılımı incelendiğinde, normal dağılımın gerektirdiği simetriyi sağlamadığı ve büyük değerlerin aykırı değerler oluşturduğu görülmektedir. Bu aykırı değerler, dağılımın sağa çarpıklaşmasına neden olmuştur. Yapılan testlerde, p-değerinin *neredeyse* %95 güven düzeyinde olduğu görülmüş ve bu doğrultuda dağılım değerlendirilmiştir.


Bu aşamadan sonra, aykırı değerler tespit edilerek temizlenmiş ve analizler bu düzeltilmiş veri seti ile devam etmiştir. **Bu işlemin bir diğer önemli faydası**, değişen varyanslılık sorununun kaynaklarından biri olan bağımlı değişkenin çarpık dağılması sorunu gidermesidir bu şekilde veri setinde mevcut olan **değişen varyanslılık sorunu ortadan kalkmış** ve daha güvenilir sonuçlar elde edilmesini sağlanmıştır.

```
# Aykırı değerleri tespit etmek için IQR metodu
Q1 <- quantile(data$y, 0.25) # 1. çeyrek
Q3 <- quantile(data$y, 0.75) # 3. çeyrek
IQR_value <- Q3 - Q1          # IQR hesaplama (çeyrekler arası aralık)

# Alt ve üst sınırları belirle
lower_bound <- Q1 - 1.5 * IQR_value
upper_bound <- Q3 + 1.5 * IQR_value

# Aykırı değerleri filtrele
data <- subset(data, y >= lower_bound & y <= upper_bound)
rownames(data) <- NULL

qqnorm(data$y)
qqline(data$y)
```



Önceki duruma kıyasla, Q-Q plot analizinde verilerin normal dağılıma çok daha iyi uyum sağladığı açıkça görülmektedir

```
lillie_test_result <- lillie.test(data$y)
print(lillie_test_result)

##
##  Lilliefors (Kolmogorov-Smirnov) normality test
```




```
##  
## data: data$y  
## D = 0.043616, p-value = 0.525
```

H_0 = işletmenin aylık kar miktarı (y) dağılımı ile normal dağılım arasında **fark yoktur**

H_1 = işletmenin aylık kar miktarı (y) dağılımı ile normal dağılım arasında **fark vardır**

Elde edilen p-değeri 0.525 olduğuna göre, %95 hatta %90 güven düzeyinde bile H_0 hipotezi **reddedilemez**. Bu sonuç, veri setinin normal dağılıma uygun olduğunu istatistiksel olarak doğrulamaktadır. Önceki aşamalarda yapılan aykırı değer temizleme işlemi ve dağılımın düzeltilmesi sayesinde, normallik varsayımı artık güçlü bir şekilde desteklenmektedir.

```
hist(data$y,  
      main = "bağımlı değişkenin Histogramı",  
      xlab = "y",  
      ylab = "Frekans",  
      col = "darkgreen",  
      border = "white",  
      breaks = 30)
```




Y değişkeninin histogramı incelendiğinde, önceki duruma kıyasla normal dağılıma daha çok benzediği görülmektedir. Aykırı değerlerin temizlenmesi ve veri setinin düzeltilmesi sonucunda, dağılımın simetrisi iyileşmiş ve daha belirgin bir normal şekil kazanmıştır.

3.2 Doğrusallık kontrolü

sürekli değişkenler(x4 hariç) arasındaki doğrusallıklara bakalım

```
pairs(data[, !names(data) %in% "x4"])
```



Bütün sayısal bağımsız değişkenler, bağımlı değişkenle doğrusal bir ilişkiye sahip gibi görünüyor. bir de korelasyon matrisine bakalım.

```
cor(data[, !names(data) %in% "x4"])
```

```
##           y           x1           x2           x3
## y  1.0000000  0.9646233  0.6957108  0.4321911
## x1  0.9646233  1.0000000  0.6399710  0.4066238
## x2  0.6957108  0.6399710  1.0000000  0.7047607
## x3  0.4321911  0.4066238  0.7047607  1.0000000
```

- **y ile x1 arasında** çok yüksek pozitif korelasyon (0.965) vardır. Bu, satış hacminin kar üzerinde güçlü bir etkisi olduğunu gösterir.
- **y ile x2 arasında** orta düzeyde pozitif korelasyon (0.696) bulunur. Bu da satış fiyatının karı artırdığını düşündürür.
- **y ile x3 arasında** zayıf pozitif korelasyon (0.432) gözlenmiştir. Bu beklenmedik bir durumdur ; üretim maliyetinin artmasıyla kar da artıyor gibi görünüyor. Detaylı analiz gerekebilir.
- **x1 ile x2 arasında** orta düzeyde pozitif korelasyon (0.640) vardır. Bu ilişki, satış fiyatı yükseldikçe satış hacminin de arttığını düşündürebilir.
- **x1 ile x3 arasında** zayıf pozitif korelasyon (0.407) bulunmuştur. Bu da üretim maliyeti artarken satış hacminin de yükseldiğini göstermektedir.
- **x2 ile x3 arasında** oldukça yüksek pozitif korelasyon (0.705) vardır. Bu, üretim maliyeti ile satış fiyatı arasında doğrusal bir ilişki olabileceğini düşündürür.

4.Çoklu regresyon modeli ve Artık İncelemesi

4.1 Çoklu regresyon modeli kurma

```
data$x4 <- as.factor(data$x4)

model <- lm(y ~ x1 + x2 + x3 + x4,data=data)
```

4.2 Artık incelemesi

Modeli kurduktan sonra artıkları tespit etmek için bir fonksiyon yazdık sonra artıkları medyanlar ile değiştirdik.

```
#Aykırı değerleri tespit etmek için bir fonksiyon yazalım
aykiri_degerler_tespit <- function(model) {
  # Gerekli fonksiyonlar genellikle 'stats' paketinden gelir ve R ile otomatik yüklenir.
  # stats:: ön ekini kullanmak, fonksiyonların doğru paketten geldiğinden emin olmayı sağlar.

  # n: Gözlem sayısı
  n_obs <- stats::nobs(model)
  if (is.null(n_obs) || n_obs == 0) {
    stop("Modelden geçerli bir gözlem sayısı (n) alınamadı veya gözlem yok.")
  }

  # k: Bağımsız değişken sayısı (sabit hariç)
  if (inherits(model, "lm")) {
    k_predictors <- length(attr(stats::terms(model), "term.labels"))
  } else {
    k_predictors <- length(stats::coef(model)) - 1
    warning("Model 'lm' tipinde değil. k_predictors, katsayı sayısından (intercept düşülerek) tahmin edildi. Lütfen doğruluğunu kontrol edin.")
  }
  if (k_predictors < 0) k_predictors <- 0

  # Model tanılamaları için temel hesaplamalar
  inf <- stats::ls.diag(model)

  # 1. Standartlaştırılmış artıklar ile Aykırı Değerler
  standartlastirilmis_aykiri <- which(inf$std.res > 2 | inf$std.res < -2)
  names(standartlastirilmis_aykiri) <- NULL

  # 2. Student Türü artıklar ile Aykırı Değerler
  studentized_residuals <- stats::rstudent(model)
  student_turu_aykiri <- which(studentized_residuals > 3 | studentized_residuals < -3)
  names(student_turu_aykiri) <- NULL

  # 3. Gözlem Uzaklığı (Leverage/Hat values) -> Uç Gözlemler
  hat_values <- inf$hat
  leverage_threshold <- 2 * (k_predictors + 1) / n_obs
```

```

plot(hat_values, pch = "*", cex = 0.7, main = "Leverage Value by Hat value",
     ylab = "Hat Değeri", xlab = "Gözlem İndeksi")
abline(h = leverage_threshold, col = "red")

labels_hat <- ifelse(hat_values > leverage_threshold,
                    if(!is.null(names(hat_values))) names(hat_values) else 1:length(hat_values),
                    "")
text(x = 1:length(hat_values), y = hat_values, labels = labels_hat, col = "red", cex = 0.8, pos = 4)

ucgozlemler <- which(hat_values > leverage_threshold)
names(ucgozlemler) <- NULL

# 4. Cook's distance -> Etkili Gözlemler
cooks_d <- stats::cooks.distance(model)
df_residual <- n_obs - k_predictors - 1
cooks_threshold <- if (n_obs > 50) {
  4 / n_obs
} else {
  if (df_residual > 0) 4 / df_residual else 1
}

plot(cooks_d, pch = "*", cex = 1, main = "Influential Obs by Cooks distance",
     ylab = "Cook's Distance", xlab = "Gözlem İndeksi")
abline(h = cooks_threshold, col = "red")

labels_cooks <- ifelse(cooks_d > cooks_threshold,
                      if(!is.null(names(cooks_d))) names(cooks_d) else 1:length(cooks_d),
                      "")
text(x = 1:length(cooks_d), y = cooks_d, labels = labels_cooks, col = "red", cex = 0.8, pos = 4)

etkili_degerler <- which(cooks_d > cooks_threshold)
names(etkili_degerler) <- NULL

# Tüm şüpheli gözlem indekslerinin birleşimi (benzersiz ve sıralı)
vektor_listesi_supheli <- list(
  standartlastirilmis_aykiri,
  student_turu_aykiri,
  ucgozlemler,
  etkili_degerler
)

vektor_listesi_dolu <- Filter(function(x) length(x) > 0, vektor_listesi_supheli)

cikarilacak_indexler_birlesim <- if (length(vektor_listesi_dolu) > 0) {
  sort(unique(Reduce(union, vektor_listesi_dolu)))
} else {
  integer(0)
}

```

```


}

# Çıktıyı Liste olarak döndür
return(list(
  standartlastirilmis_aykiri = standartlastirilmis_aykiri,
  student_turu_aykiri = student_turu_aykiri,
  uc_gozlemler = ucgozlemler,
  etkili_degerler = etkili_degerler,
  tum_supheli_gozlemler_birlesim = cikarilacak_indexler_birlesim
))
}


data_artik_incelemeesi <- aykiri_degerler_tespit(model)

```

Influential Obs by Cook's distance



Leverage Value by Hat value



```

print(data_artik_incelemeesi)

## $standartlastirilmis_aykiri
## [1] 79 112 113 114 115 116 117 118 119 120 121 122 123 124 125 126
##
## $student_turu_aykiri
## [1] 123
##
## $uc_gozlemler
## [1] 15 21 48 56 72 79 99 127 134 135 166
##
## $etkili_degerler
## [1] 48 79 112 113 114 115 116 117 118 119 120 121 122 123 124 125 126
127
##
## $tum_supheli_gozlemler_birlesim
## [1] 15 21 48 56 72 79 99 112 113 114 115 116 117 118 119 120 121
122 123
## [20] 124 125 126 127 134 135 166

#tüm aykırı değerlerin indexlerini alalım
tum_supheli_gozlemler_birlesim <- data_artik_incelemeesi$tum_supheli_gozlemler_birlesim
print(tum_supheli_gozlemler_birlesim)

## [1] 15 21 48 56 72 79 99 112 113 114 115 116 117 118 119 120 121
122 123
## [20] 124 125 126 127 134 135 166

#aykırıları medyanla değiştirelim
data_yeni <- data
# 2. Aykırı indekslerin geçerliliğini kontrol et (pozitif ve data_yeni sınırları içinde)
if (exists("data_yeni") && exists("tum_supheli_gozlemler_birlesim")) {

  gecerli_aykiri_indeksler <- tum_supheli_gozlemler_birlesim[
    tum_supheli_gozlemler_birlesim > 0 &
    tum_supheli_gozlemler_birlesim <= nrow(data_yeni)
  ]

  # 3. Eğer geçerli aykırı indeks varsa işleme devam et
  if (length(gecerli_aykiri_indeksler) > 0) {

    # 4. Veri çerçevesindeki her bir sütun için döngü
    for (sutun_idx in 1:ncol(data_yeni)) {

      # Mevcut sütunun adını al
      sutun_adi_mevcut <- names(data_yeni)[sutun_idx]

      # 5. Sütunun sayısal olup olmadığını VE "x4" OLMADIĞINI kontrol et
      if (is.numeric(data_yeni[[sutun_idx]]) && sutun_adi_mevcut != "x4") {

        # 6. Sütunun medyanını hesapla (NA değerlerini göz ardı ederek)

```

```

# Medyan, o anki sütun değerleri üzerinden hesaplanır.
sutun_medyani <- median(data_yeni[[sutun_idx]], na.rm = TRUE)

# 7. Belirtilen geçerli aykırı satırlardaki bu sütunun değerini medyan ile değiştir
data_yeni[gecerli_aykiri_indeksler, sutun_idx] <- sutun_medyani

# print(paste("", sutun_adi_mevcut, "' sütunundaki aykırı değerler medyan", round(sutun_medyani, 2), ") ile güncellendi.", sep=""))
}
}

print(paste(length(gecerli_aykiri_indeksler), "satırdaki uygun sayısal sütunların (x4 sütunu hariç) değerleri, kendi sütun medyanları ile güncellendi."))

} else {
  print("Sağlanan aykırı indeks listesi boş veya `data_yeni` için geçerli indeks içermiyor. Veri çerçevesinde değişiklik yapılmadı.")
}

} else {
  print("`data_yeni` veya `tum_supheli_gozlemler_birlesim` R ortamında bulunamadı. Lütfen tanımlı olduklarından emin olun.")
}

```

```
## [1] "26 satırdaki uygun sayısal sütunların (x4 sütunu hariç) değerleri, kendi sütun medyanları ile güncellendi."
```

5. Elde edilen model

5.1 model anlamlılığı test et

Artık incelmesinden sonra yeni veri setimizle devam ediyoruz adı da *data_yeni*.

```

sonuc <- lm(y ~ x1 + x2 + x3 + x4, data = data_yeni)
summary(sonuc)

##
## Call:
## lm(formula = y ~ x1 + x2 + x3 + x4, data = data_yeni)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.8322 -0.3369  0.0023  0.5036  4.2771
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.67824    0.49832   3.368 0.000927 ***
## x1          10.36639    0.09676 107.136 < 2e-16 ***
## x2           2.44341    0.12063  20.256 < 2e-16 ***
## x3          -0.57694    0.09665  -5.969 1.24e-08 ***

```

```
## x42          -1.49535      0.14664 -10.197 < 2e-16 ***
## x43          -6.10936      0.14868 -41.091 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.8235 on 180 degrees of freedom
## Multiple R-squared:  0.9936, Adjusted R-squared:  0.9934
## F-statistic: 5570 on 5 and 180 DF, p-value: < 2.2e-16
```

$H_0: \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = 0$ (model anlamlı **değildir**.)

$H_1: \beta_i \neq 0$ (i = 1,2,3,4,5) model anlamlıdır.

p-değeri 0.05 den küçük olduğu için H_0 **red edilir**, model %95 güven düzeyinde anlamlıdır.

5.2 model kestirimi yaz

$$\hat{y} = 1.67 + \underset{(0.49832)}{10.36x_1} + \underset{(0.09676)}{2.44x_2} - \underset{(0.12063)}{0.57x_3} - \underset{(0.14664)}{1.49 \cdot I(x_4 = 2)} - \underset{(0.14868)}{6.10 \cdot I(x_4 = 3)}$$

Açıklamalar:

- $\hat{y}$: Tahmin edilen kar miktarı (TL cinsinden).
- x_1 : Satış hacmi (birim sayısı).
- x_2 : Ortalama satış fiyatı (TL cinsinden).
- x_3 : Birim üretim maliyeti (TL cinsinden).
- $I(x_4=2)$: Gözlem "Hedefli Pazarlama" stratejisini kullanıyorsa 1, değilse 0.
- $I(x_4=3)$: Gözlem "Yaratıcı Pazarlama" stratejisini kullanıyorsa 1, değilse 0.

Bu modelde Düzey 1 ("Standart Pazarlama") , referans kategori olarak alınmıştır.

6. Regresyon katsayılarının anlamlılıklarını inceleyiniz ve katsayıları yorumlayınız.

Katsayıların İstatistiksel Anlamlılığı

- Sabit terim (Intercept) : p-değeri 0.000927 'dir. Bu değer %1 anlamlılık düzeyinden küçük olduğu için sabit terim istatistiksel olarak anlamlıdır.
- Satış Hacmi (x_1) : p-değeri < 2e-16 'dır. Bu değer çok küçük olduğu için satış hacminin kar üzerindeki etkisi son derece anlamlıdır.
- Satış Fiyatı (x_2) : p-değeri < 2e-16 'dır. Bu da satış fiyatının kar üzerindeki etkisinin istatistiksel olarak çok güçlü bir şekilde anlamlı olduğunu gösterir.

- Üretim Maliyeti (**x3**) : p-değeri 1.24e-08 'dir. Bu değer oldukça küçük olduğundan, üretim maliyetinin kar üzerindeki etkisi istatistiksel olarak anlamlıdır.
- Hedefli Pazarlama (**x42**) : p-değeri $< 2e-16$ 'dır. Bu sonuç, hedefli pazarlama stratejisinin kar üzerindeki etkisinin istatistiksel olarak anlamlı olduğunu göstermektedir.
- Yaratıcı Pazarlama (**x43**) : p-değeri $< 2e-16$ 'dır. Bu da yaratıcı pazarlama stratejisinin kar üzerindeki etkisinin istatistiksel olarak son derece anlamlı olduğunu gösterir.

Her bir değişken için yapılan t-testi sonuçlarına göre , p-değerleri %5 anlamlılık düzeyinden ($\alpha = 0.05$) çok daha küçük olduğu için bütün katsayılar istatistiksel olarak anlamlıdır . Bu durum, tüm bağımsız değişkenlerin kar (y) üzerinde önemli bir etkiye sahip olduğunu göstermektedir.

Katsayı yorumlası

1. Sabit Terim (Intercept):

Tahmini: 1.67824

Diğer tüm değişkenler sıfır kabul edildiğinde, beklenen kar yaklaşık 1.68 TL 'dir. Ancak bu sabit terim, gerçek hayatta mantıksal olmayan bir senaryoyu yansıtabilir çünkü satış hacmi, fiyat ve maliyetin hepsi sıfır iken kar olması beklenmez.

2. x1 (Satış Hacmi):

Tahmini: 10.36639

Satış hacminin her bir birim artışı, diğer tüm değişkenler sabit tutulduğunda, karın ortalama 10.37 TL artmasına neden olur. Bu oldukça yüksek ve pozitif bir etkidir. Satış hacmi, kar üzerinde en güçlü pozitif etkiye sahip değişken olarak öne çıkmaktadır.

3. x2 (Satış Fiyatı):

Tahmini: 2.44341

Diğer tüm değişkenler sabit tutulduğunda ortalama satış fiyatı 1 TL arttığında, kar ortalama 2.44 TL artmaktadır . Bu da satış fiyatının kar üzerinde pozitif bir etkisi olduğunu gösterir.

4. x3 (Üretim Maliyeti):

Tahmini: -0.57694

Diğer tüm değişkenler sabit tutulduğunda birim üretim maliyetinin 1 TL artması, karın ortalama 0.58 TL azalmasına neden olur. Bu, üretim maliyetinin kar üzerinde negatif bir etkisi olduğunu göstermektedir.

5. x42 (Hedefli Pazarlama):

Tahmini: -1.49535

Diğer tüm değişkenler sabit tutulduğunda standart pazarlamaya göre hedefli pazarlama stratejisinin uygulanması, karın ortalama 1.49 TL azalmasına neden olur. Bu, hedefli pazarlama stratejisinin kar üzerinde negatif bir etkiye sahip olduğunu gösterir.

6. x43 (Yaratıcı Pazarlama):

Tahmini: -6.10936

Diğer tüm değişkenler sabit tutulduğunda standart pazarlamaya kıyasla yaratıcı pazarlama stratejisinin uygulanması, karın ortalama 6.11 TL azalmasına neden olur. Bu etki oldukça büyük ve negatiftir. Bu nedenle, yaratıcı pazarlama stratejisinin kar üzerinde ciddi bir düşüşe yol açtığı söylenebilir.

7. Belirtme katsayısını ya da düzeltilmiş belirtme katsayısını yorumlayınız.

Regresyon modelinden elde edilen uyum ölçütleri şu şekildedir:

- Belirtme Katsayısı (Multiple R-squared): 0.9936
- Düzeltilmiş Belirtme Katsayısı (Adjusted R-squared): 0.9934

Yorum:

- Multiple R-squared değeri (%99.36) , bağımsız değişkenlerin (**x1, x2, x3, x4**) bağımlı değişken olan kar (**y**)'nin varyansının yaklaşık %99.36'sını açıkladığını göstermektedir. Bu oldukça yüksek bir orandır ve modelin veriye çok iyi uyduğunu gösterir.
- Ancak bu değer, modele eklenen her yeni değişken için otomatik olarak arttığından dolayı yanıltıcı olabilir. Bu nedenle daha gerçekçi değerlendirme için düzeltilmiş belirtme katsayısı (Adjusted R-squared) kullanılır.
- Adjusted R-squared değeri (%99.34) de oldukça yüksek bir değerdir ve modele eklenen değişkenlerin fazladan açıklama gücüne sahip olmadığını da göstermektedir. Modelin sadeleştirilmesi düşünülebilir; ancak bu aşamada model zaten oldukça güçlüdür.

Sonuç:

Model, kar üzerinde etkili olan değişkenleri çok iyi açıklayabilmekte ve veriye son derece iyi uymaktadır. Hem Multiple R-squared hem de Adjusted R-squared değerleri çok yüksek olduğu için modelin tahmin gücünün oldukça güçlü olduğu söylenebilir.

8. Regresyon katsayıları için %99 güven aralıkları

```
confint(sonuc, level = 0.99)
```

```
##              0.5 %      99.5 %  
## (Intercept) 0.3809092 2.9755767  
## x1          10.1144878 10.6182968  
## x2           2.1293629 2.7574545  
## x3          -0.8285641 -0.3253129  
## x42         -1.8771146 -1.1135835  
## x43         -6.4964331 -5.7222844
```

Yorumlar:

- Sabit Terim (Intercept) :
%99 güven düzeyinde sabit terimin gerçek değeri 0.38 ile 2.98 arasında olabilir. Bu aralık sıfırı içermemektedir, bu da sabit terimin anlamlı olduğunu destekler.
- Satış Hacmi (x1) :
Gerçek katsayının %99 güvenle 10.11 ile 10.62 arasında olacağı tahmin edilmektedir. Bu aralık pozitif olduğu için satış hacminin kar üzerindeki pozitif etkisi oldukça güçlüdür.
- Satış Fiyatı (x2) :
Gerçek katsayının %99 güvenle 2.13 ile 2.76 arasında olacağı tahmin edilmektedir. Bu da satış fiyatının kar üzerinde pozitif ve istatistiksel olarak anlamlı bir etkiye sahip olduğunu göstermektedir.
- Üretim Maliyeti (x3) :
Gerçek katsayının %99 güvenle -0.83 ile -0.33 arasında olacağı tahmin edilmektedir. Bu aralık tamamen negatif olduğundan, üretim maliyetinin kar üzerindeki negatif etkisinin çok güçlü olduğu söylenebilir.
- Hedefli Pazarlama (x42) :
Gerçek katsayının %99 güvenle -1.88 ile -1.11 arasında olacağı tahmin edilmektedir. Bu da hedefli pazarlama stratejisinin karı azalttığını gösterir.
- Yaratıcı Pazarlama (x43) :
Gerçek katsayının %99 güvenle -6.50 ile -5.72 arasında olacağı tahmin edilmektedir. Bu, yaratıcı pazarlama stratejisinin kar üzerinde en güçlü negatif etkiye sahip olduğunu göstermektedir.

Genel Sonuç:


Tüm değişkenler için hesaplanan %99 güven aralıkları, her bir katsayının sıfırdan farklı olduğunu ve dolayısıyla tüm değişkenlerin kar üzerinde istatistiksel olarak önemli bir etkiye sahip olduğunu göstermektedir. Özellikle **x1** (satış hacmi) ve **x43** (yaratıcı pazarlama) gibi değişkenlerdeki dar güven aralığı, tahminlerin yüksek güvenilirlikte olduğunu gösterir.

9. Değişen varyanslılık sorunu incelemesi

9.1 Grafiksel Yöntem ile

```
inf = ls.diag(sonuc)
#Değişen varyanslılık kontrolü

#grafiksel yöntem
plot(predict(sonuc), inf$stud.res, ylab="Studentized Residuals", xlab="Predicted Value")
```



Grafik, bir megafon şeklinde belirgin bir yapı sergilemiyor ve rastgele dağılım gösteriyor—bu durum, değişen varyansın olmadığını kanıtlıyor. Üstteki grafiğin nicel bir temsili olarak aşağıdaki regresyon testi yapılabilir.

```
summary(lm(abs(residuals(sonuc)) ~ fitted(sonuc)))

##
## Call:
## lm(formula = abs(residuals(sonuc)) ~ fitted(sonuc))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.5174 -0.3239 -0.1812  0.0636  3.7560
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.5632481  0.3044277   1.850   0.0659 .
## fitted(sonuc) -0.0006734  0.0045521  -0.148   0.8826
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##  
## Residual standard error: 0.6256 on 184 degrees of freedom  
## Multiple R-squared: 0.0001189, Adjusted R-squared: -0.005315  
## F-statistic: 0.02188 on 1 and 184 DF, p-value: 0.8826
```

$H_0 : \beta_1 = 0 \rightarrow$ Tahmini değerlerin artıklar üzerinde anlamlı bir etkisi yoktur. $\rightarrow$ Varyans sabittir

$H_1 : \beta_1 \neq 0 \rightarrow$ Tahmini değerlerin artıklar üzerinde anlamlı bir etkisi vardır. $\rightarrow$ Varyans sabit değildir.

p-değeri > 0.05 den büyük olduğu için %95 güven düzeyinde H_0 hipotezi red edilemez ve değişen varyanslılık sorunu yoktur.

9.2 Breusch-Pagan test yöntemi ile

```
library(lmtest)  
  
## Zorunlu paket yükleniyor: zoo  
  
##  
## Attaching package: 'zoo'  
  
## The following objects are masked from 'package:base':  
##  
##      as.Date, as.Date.numeric  
  
bptest(sonuc)  
  
##  
## studentized Breusch-Pagan test  
##  
## data: sonuc  
## BP = 6.2016, df = 5, p-value = 0.2871
```

H_0 : Varyanslar homojendir


H_1 : Varyans homojen değildir.

P-değeri 0.05'ten büyük olduğundan, %95 güven düzeyinde H_0 hipotezi reddedilemez. Bu durum, değişen varyanslılık (heteroskedastisite) sorununun olmadığını gösterir ve regresyon modelinde artıkların sabit varyansa sahip olduğunu destekler.

10. Öz ilişki sorununu incelemesi

10.1 Grafiksel yöntem ile

```
plot(inf$stud.res[1:length(inf$stud.res)-1],inf$stud.res[2:length(inf$stud.res)],xlab = "i-1. student artık",ylab="i. student artık")
```



Grafikte görüldüğü üzere hataların birbirleri arasında rasgele dağılmadığı ilişkili olduğu görülüyor. Ancak kesin sonuç için Durbin Watson test ile test etmeliyiz.

10.2 Durbin-Watson Test yöntemi ile

```
dwtest(sonuc)
```

```
##
## Durbin-Watson test
##
## data: sonuc
## DW = 0.97775, p-value = 3.625e-13
## alternative hypothesis: true autocorrelation is greater than 0
```

$H_0 : \rho = 0 \rightarrow$ öz ilişki yoktur

$H_1 : \rho > 0 \rightarrow$ pozitif öz ilişki vardır.

p-değeri 0.05 den küçük olduğu için %95 güven düzeyinde H_0 hipotezi red edilir ve hatalar arasında pozitif öz ilişki olduğu söylenir.

Otokorelasyonun Regresyon Analizine Etkileri:

- En Küçük Kareler (EKK) Tahmincileri hâlâ yansızdır , ancak artık en küçük varyanslı (BLUE – Best Linear Unbiased Estimator) değildir. Bu da tahminlerin etkinliğini kaybetmesine neden olur.
- Hata terimi varyansı olan σ^2 kestirimi sapmalı ve tutarsız olur.
- Katsayıların standart hataları gerçek değerlerinden daha küçük tahmin edilir.
- Bu durumda oluşturulan güven aralıkları dar ve yanıltıcı , hipotez testleri ise aşırı anlamlılık gösterir .

Bu sorunlar, modelden yapılacak tahminlerin güvenilirliğini düşürür ve çıkarımsal istatistik sonuçlarının geçerliliğini zedeler.

Çözüm Önerisi:

Bu tür otokorelasyon sorununu gidermek veya en aza indirmek için Cochrane–Orcutt yöntemi kullanılabilir.

11. Çoklu bağlantı sorununu incelemesi

```
library(car)
```

```
## Zorunlu paket yükleniyor: carData
```

```
vif(sonuc)
```

```
##          GVIF Df GVIF^(1/(2*Df))
## x1 1.746519  1      1.321559
## x2 2.721508  1      1.649699
## x3 1.905254  1      1.380309
## x4 1.010224  2      1.002546
```

Tüm VIF değerleri 10 dan küçük olduğu için bu modelde çoklu bağlantı sorunu yoktur.

12. Veri kümesi içinden seçeceğiniz herhangi bir gözlem için uyum kestirimini bulunuz.

uyum kestirimi için önce veri den bir gözlem seçelim:

```
secilen_gozlem <- data_yeni[10, ]
secilen_gozlem
```

```
##          y          x1          x2          x3 x4
## 10 74.18802 6.514278 3.116861 5.550211  1
```

sonra uyum kestirimi yapalım

```
uyum_degeri <- predict(sonuc, newdata = secilen_gozlem)
uyum_degeri
```

```
##      10
## 73.62144
```

Seçilen gözlem için bağımsız değişkenlerin değerleri şu şekildedir:

- Satış hacmi (**x1**): 6.514278
- Ortalama satış fiyatı (**x2**): 3.116861
- Üretim maliyeti (**x3**): 5.550211
- Pazarlama stratejisi (**x4**): Standart pazarlama (Düzey 1)

Bu gözlem için regresyon modelinden elde edilen uyum kestirimi (tahmini kar) yaklaşık 74.18 TL olarak bulunmuştur. Bu değer, modelin bu gözlem için hesapladığı beklenen kar miktarını temsil etmektedir. Gerçek kar değeri de 74.18802 TL olduğu için, modelin bu gözlem için oldukça doğru bir tahmin yapmış olduğu görülmektedir.

13. Veri kümesinde bulunmayan herhangi bir gözlem için ön kestirimi bulunuz.

önce veri kümesinde olmayan bir gözlem oluşturalım.

```
library(dplyr)

##
## Attaching package: 'dplyr'

## The following object is masked from 'package:car':
##
##      recode

## The following objects are masked from 'package:stats':
##
##      filter, lag

## The following objects are masked from 'package:base':
##
##      intersect, setdiff, setequal, union

# Yeni gözlemi oluştururken veri kümesindeki x4 ile aynı düzeyleri kullan:
yeni_gozlem_df <- data.frame(
  x1 = 6.0,
  x2 = 3.5,
  x3 = 4.0,
  x4 = factor("2", levels = levels(data_yeni$x4)) # Aynı düzeyler!
)

# Şimdi filtreleme güvenli şekilde yapılabilir:
eslesen_satirlar <- data_yeni %>%
  filter(
    x1 == yeni_gozlem_df$x1,
    x2 == yeni_gozlem_df$x2,
```



```

    x3 == yeni_gozlem_df$x3,
    x4 == yeni_gozlem_df$x4
  )

# Sonuç kontrolü
if (nrow(eslesen_satirlar) > 0) {
  print("Bu gözlem veri kümesinde ZATEN VAR.")
} else {
  print("Bu gözlem veri kümesinde YOK, yeni bir gözlemdir.")
}

## [1] "Bu gözlem veri kümesinde YOK, yeni bir gözlemdir."

```

sonra ön kestirimi yapalım.

```

on_kestirim_degeri <- predict(sonuc, newdata = yeni_gozlem_df)
on_kestirim_degeri

##          1
## 68.62542

```

Regresyon modeli kullanılarak veri kümesinde yer almayan, ancak anlamlı ve gerçekçi değerlere sahip bir gözlem için ön kestirim (prediction) yapılmıştır. Bu yeni gözlemin özellikleri şu şekildedir:

- Satış Hacmi (**x1**) : 6.0 birim
- Satış Fiyatı (**x2**) : 3.5 TL
- Üretim Maliyeti (**x3**) : 4.0 TL
- Pazarlama Stratejisi (**x4**) : Hedefli pazarlama (Düzey 2)

Bu değerlere göre modelden yapılan tahmine göre beklenen kar miktarı yaklaşık 69.17 TL olarak bulunmuştur.

14 . (12) ve (13)'te bulduğunuz kestirimlerden yararlanarak $\hat{y}$ için güven aralıklarını %95 güven düzeyinde bulunuz ve yorumlayınız.

14.1 Uyum Kestirimi İçin Güven Aralığı

```

uyum_kestirimi_guven <- predict(sonuc, newdata = secilen_gozlem, interval =
"confidence", level= 0.95)
uyum_kestirimi_guven

##          fit          lwr          upr
## 10 73.62144 73.25653 73.98635

```

- Tahmini Kar (**fit**) : 73.62 TL
- Alt Güven Sınırı (**lwr**) : 73.26 TL

- Üst Güven Sınırı (**upr**) : 73.99 TL

Seçilen gözlem için regresyon modelinden elde edilen tahmini kar miktarı yaklaşık 73.62 TL olarak bulunmuştur. Bu tahminin %95 güven düzeyindeki güven aralığı ise [73.26, 73.99] TL arasındadır.

Bu dar güven aralığı, modelin bu gözlem noktası için yaptığı tahminin oldukça kesin ve güvenilir olduğunu göstermektedir. Ayrıca gerçek kar değeri olan 74.19 TL, güven aralığının dışında kalsa da fark oldukça küçük olduğu için modelin genel olarak iyi çalıştığı söylenebilir.

Uyum kestirimleri için kullanılan "confidence interval", sadece regresyon katsayılarındaki belirsizliği dikkate alır. Bu nedenle daha dar bir aralık verir. Bu bağlamda, modelin mevcut veriye uyumunun yüksek olduğu, dolayısıyla başarılı bir tahmin yeteneğine sahip olduğu sonucuna ulaşılır.

14.2 Ön Kestirimi İçin Güven Aralığı

```
on_kestirimi_guven <- predict(sonuc, newdata = yeni_gozlem_df, interval = "
prediction", level = 0.95)
on_kestirimi_guven
```

##	fit	lwr	upr
## 1	68.62542	66.9816	70.26925

- Tahmini Kar (**fit**) : 68.63 TL
- Alt Kestirim Sınırı (**lwr**) : 66.98 TL
- Üst Kestirim Sınırı (**upr**) : 70.27 TL

Veri kümesinde yer almayan, ancak anlamlı ve gerçekçi değerlere sahip yeni bir gözlem için yapılan ön kestirim sonucunda tahmini kar yaklaşık 68.63 TL olarak elde edilmiştir. Bu tahminin %95 güven düzeyindeki kestirim aralığı ("prediction interval") [66.98, 70.27] TL arasındadır.

Prediction interval tercih edildiği zaman, hem model parametrelerindeki belirsizlik, hem de yeni gözlemden kaynaklanan rastgelelik dikkate alınmaktadır. Bu nedenle, prediction interval, confidence interval'e göre daha geniş olur. Ancak bu aralığın yine de nispeten dar olması, modelin yeni verilere iyi genellediğini ve güvenilir tahminler üretebildiğini göstermektedir.

Dolayısıyla, bu tür yeni gözlemler için yapılacak kar tahminlerinin yüksek doğrulukta olacağı öngörülmektedir.

15. Değişken seçimi yöntemlerini kullanarak en iyi modeli bulma

Tüm adımsal teknikler kullanılmıştır.

```
## İleriye Doğru Seçim (Forward selection)
library(stats)
lm.null <- lm(y ~ 1 , data = data_yeni)
forward <- step(lm.null,y ~ x1 + x2 + x3 + x4, data = data_yeni, direction
= "forward")

## Start:  AIC=862.59
## y ~ 1
##
##          Df Sum of Sq    RSS    AIC
## + x1      1  17362.2  1644.8 409.41
## + x2      1   9690.2  9316.8 731.97
## + x3      1   3810.4 15196.6 822.97
## + x4      2   1295.1 17711.9 853.46
## <none>                19007.0 862.59
##
## Step:  AIC=409.41
## y ~ x1
##
##          Df Sum of Sq    RSS    AIC
## + x4      2   1203.25  441.53 168.80
## + x2      1    280.68 1364.11 376.61
## + x3      1     52.18 1592.60 405.41
## <none>                1644.78 409.41
##
## Step:  AIC=168.8
## y ~ x1 + x4
##
##          Df Sum of Sq    RSS    AIC
## + x2      1   295.308  146.22 -34.753
## + x3      1    41.244  400.29 152.557
## <none>                441.53 168.798
##
## Step:  AIC=-34.75
## y ~ x1 + x4 + x2
##
##          Df Sum of Sq    RSS    AIC
## + x3      1    24.163  122.06 -66.348
## <none>                146.22 -34.753
##
## Step:  AIC=-66.35
## y ~ x1 + x4 + x2 + x3

forward

##
## Call:
```

```
## lm(formula = y ~ x1 + x4 + x2 + x3, data = data_yeni)
##
## Coefficients:
## (Intercept)          x1          x42          x43          x2
x3
##      1.6782      10.3664      -1.4953      -6.1094      2.4434      -0.
5769

summary(forward)

##
## Call:
## lm(formula = y ~ x1 + x4 + x2 + x3, data = data_yeni)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.8322 -0.3369  0.0023  0.5036  4.2771
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.67824    0.49832   3.368 0.000927 ***
## x1           10.36639    0.09676 107.136 < 2e-16 ***
## x42          -1.49535    0.14664 -10.197 < 2e-16 ***
## x43          -6.10936    0.14868 -41.091 < 2e-16 ***
## x2            2.44341    0.12063  20.256 < 2e-16 ***
## x3           -0.57694    0.09665  -5.969 1.24e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.8235 on 180 degrees of freedom
## Multiple R-squared:  0.9936, Adjusted R-squared:  0.9934
## F-statistic: 5570 on 5 and 180 DF, p-value: < 2.2e-16

## Geriye Doğru Seçim (Backward elimination)
backward<-step(sonuc,direction="backward")

## Start: AIC=-66.35
## y ~ x1 + x2 + x3 + x4
##
##           Df Sum of Sq  RSS   AIC
## <none>                 122.1 -66.35
## - x3      1         24.2 146.2 -34.75
## - x2      1        278.2 400.3 152.56
## - x4      2       1229.5 1351.6 376.89
## - x1      1       7783.5 7905.6 707.42

summary(backward)

##
## Call:
## lm(formula = y ~ x1 + x2 + x3 + x4, data = data_yeni)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.8322 -0.3369  0.0023  0.5036  4.2771
```

```
##
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.67824    0.49832   3.368 0.000927 ***
## x1          10.36639    0.09676 107.136 < 2e-16 ***
## x2           2.44341    0.12063  20.256 < 2e-16 ***
## x3          -0.57694    0.09665  -5.969 1.24e-08 ***
## x42          -1.49535    0.14664 -10.197 < 2e-16 ***
## x43          -6.10936    0.14868 -41.091 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.8235 on 180 degrees of freedom
## Multiple R-squared:  0.9936, Adjusted R-squared:  0.9934
## F-statistic: 5570 on 5 and 180 DF, p-value: < 2.2e-16

## Adımsal Seçim Yöntemi (Stepwise elimination)
library(MASS)

##
## Attaching package: 'MASS'

## The following object is masked from 'package:dplyr':
##
##      select

step.model <- stepAIC(sonuc, direction = "both", trace = FALSE)
summary(step.model)

##
## Call:
## lm(formula = y ~ x1 + x2 + x3 + x4, data = data_yeni)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.8322 -0.3369  0.0023  0.5036  4.2771
##
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.67824    0.49832   3.368 0.000927 ***
## x1          10.36639    0.09676 107.136 < 2e-16 ***
## x2           2.44341    0.12063  20.256 < 2e-16 ***
## x3          -0.57694    0.09665  -5.969 1.24e-08 ***
## x42          -1.49535    0.14664 -10.197 < 2e-16 ***
## x43          -6.10936    0.14868 -41.091 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.8235 on 180 degrees of freedom
## Multiple R-squared:  0.9936, Adjusted R-squared:  0.9934
## F-statistic: 5570 on 5 and 180 DF, p-value: < 2.2e-16
```

Bu çalışmada değişken seçimi için üç farklı yöntem kullanılmıştır: İleriye doğru seçim, geriye doğru eleme ve adımsal seçim. Tüm yöntemler sonucunda en iyi model şu şekilde elde edilmiştir:

$$y \sim x_1 + x_2 + x_3 + x_4$$

- **İleriye doğru seçim (Forward Selection):** Karar verme sürecinde en fazla katkıyı sağlayan değişkenler sırayla modele eklenmiş; sonunda tüm değişkenlerin modele dahil olması gerektiği görülmüştür.
- **Geriye doğru eleme (Backward Elimination):** Tüm değişkenlerle başlayan modelde, hiçbir değişken çıkarıldığında AIC değerinde iyileşme sağlanamadığından tüm değişkenlerin kalması gerektiği sonucuna ulaşılmıştır.
- **Adımsal seçim (Stepwise Selection):** Hem ekleme hem çıkarma işlemleriyle en düşük AIC değerine ulaşılırken, en iyi model yine tüm değişkenleri içeren model olmuştur.

Elde edilen modelin çok yüksek R^2 (0.9936) ve istatistiksel olarak anlamlı F-testi sonuçları vardır. Bu da modelin veriye çok iyi uyduğunu ve tüm değişkenlerin kar üzerinde önemli bir etkiye sahip olduğunu göstermektedir.

Dolayısıyla, değişken seçimi yöntemleri sonucunda elde edilen "**en iyi model**", **orijinal modeldir**. Bu model, hem açıklama gücü hem de istatistiksel anlamlılık açısından en uygun model olarak değerlendirilmiştir.


16. Ridge regresyon modelini kurarak ridge izi grafiğini yorumlayınız.

```
library(MASS)
ridge <- lm.ridge(sonuc ,lambda = seq(0,1,0.05))
# Matplotlib ile grafiği çizecek kod
matplot(
  ridge$lambda,          # X eksen: Lambda değerleri
  t(ridge$coef),         # Y eksen: Katsayılar (beta)
  type = "l",            # Çizgi tipi: Lineer
  xlab = expression(lambda), # X eksen etiketi: Lambda
  ylab = expression(hat(beta)), # Y eksen etiketi: Beta katsayıları
  col = rainbow(ncol(ridge$coef)) # Renkler: Farklı bağımsız değişkenler i
  #in farklı renkler
)
#x eksenine ridge deki lambdaları al. y için transpoz(t) ridge$coef al.
# Legend eklemek için:
legend(
  "topright",           # Konum: Grafik sağ üst köşesi
  legend = names(coef(sonuc)), # Legend etiketleri: Bağımsız değişken isim
```

```

leri
lty = 1, # Çizgi tipleri: Tümü düz çizgi
col = rainbow(ncol(ridge$coef)), # Renkler: Aynı matplotlib'taki renkler
bty = "n" # Sınırlayıcı kutu: Yok
)
abline(h=0,lwd=2)

```



Tüm bağımsız değişkenler paraleledir , hızlı artış veya azalış yoktur o yüzden bağımsız değişkenler arasında çoklu bağlantı yoktur.

Ridge regresyon katsayıları

Aşağıda, farklı lambda (λ) değerlerine göre Ridge regresyonunun elde ettiği katsayılar verilmiştir:

```

ridge$coef
##           0.00           0.05           0.10           0.15           0.20           0.25
## x1  8.5490584  8.5456871  8.5423196  8.5389560  8.5355963  8.5322404
## x2   2.0176593  2.0187519  2.0198412  2.0209274  2.0220104  2.0230901
## x3  -0.4974977 -0.4967157 -0.4959335 -0.4951512 -0.4943686 -0.4935858
## x42 -0.7077053 -0.7068003 -0.7058965 -0.7049939 -0.7040925 -0.7031924
## x43 -2.8432206 -2.8420522 -2.8408849 -2.8397188 -2.8385539 -2.8373901
##           0.30           0.35           0.40           0.45           0.50           0.55
## x1  8.5288883  8.5255401  8.5221957  8.5188551  8.5155184  8.5121854

```

```
## x2 2.0241668 2.0252402 2.0263105 2.0273777 2.0284417 2.0295026
## x3 -0.4928029 -0.4920198 -0.4912365 -0.4904531 -0.4896694 -0.4888857
## x42 -0.7022935 -0.7013958 -0.7004994 -0.6996042 -0.6987102 -0.6978174
## x43 -2.8362274 -2.8350658 -2.8339054 -2.8327462 -2.8315880 -2.8304310
## 0.60 0.65 0.70 0.75 0.80 0.85
## x1 8.5088562 8.5055308 8.5022092 8.4988913 8.4955772 8.4922669
## x2 2.0305605 2.0316152 2.0326668 2.0337154 2.0347609 2.0358033
## x3 -0.4881017 -0.4873177 -0.4865334 -0.4857491 -0.4849645 -0.4841799
## x42 -0.6969258 -0.6960354 -0.6951463 -0.6942583 -0.6933716 -0.6924860
## x43 -2.8292751 -2.8281204 -2.8269667 -2.8258142 -2.8246628 -2.8235126
## 0.90 0.95 1.00
## x1 8.4889603 8.4856574 8.4823583
## x2 2.0368427 2.0378790 2.0389124
## x3 -0.4833951 -0.4826102 -0.4818251
## x42 -0.6916016 -0.6907185 -0.6898365
## x43 -2.8223634 -2.8212154 -2.8200685
```

λ arttıkça katsayıların sıfıra yaklaştığı görülmektedir lakin hiçbir bağımsız değişkenin katsayılarında ani bir düşüş olmadığı için çoklu bağlantı yoktur.

Ridge regresyonu için en iyi λ değerinin bulunması için aşağıdaki kod yardımcı olur.

```
select(ridge)

## modified HKB estimator is 0.02365812
## modified L-W estimator is 0.0200366
## smallest value of GCV at 0.05
```

HKB (Hoerl–Kennard–Baldwin) tahmini: 0.02365812

L-W (Lawless–Wang) tahmini: 0.0200366

GCV'nin minimum olduğu λ değeri: 0.05

GCV'nin minimum olduğu λ değeri temel alınarak, en iyi Ridge regresyon modeli için $\lambda = 0.05$ değeri seçilmiştir. Bu değer, çoklu bağlantı sorununu azaltırken, aynı zamanda modelin açıklamaya gücünü yüksek düzeyde koruyan dengeli bir Ridge parametresidir.

Bu seçim sayesinde, modelden gelen aşırı uydurma (overfitting) riski azaltılmış ve değişkenler arasındaki güçlü ilişkiler daha iyi kontrol altına alınmıştır.

GCV kriteri, özellikle:

- Çok küçük lambda ($\lambda \approx 0$) → aşırı uyuma (overfitting) yol açabilir,
- Çok büyük lambda (λ yüksek) → katsayıları sıfıra fazla çekerek açıklama gücünü düşürür,

...durumlarını cezalandırır ve orta seviyede bir lambda önerir. Bu nedenle GCV, uygulamalı çalışmalarda sıkça tercih edilen bir Ridge parametresi seçim kriteridir.

```
ridge$coef[,ridge$lam == 0.05]
```


##	x1	x2	x3	x42	x43
##	8.5456871	2.0187519	-0.4967157	-0.7068003	-2.8420522

$\lambda = 0.05$ için elde edilen Ridge katsayıları şu şekildedir:

Ridge regresyon sadece bağımsız değişkenlerin katsayılarını düzenler , sabit terim ise orijinal modelden aynen alınır.

- x1 (Satış Hacmi): 8.5456871
- x2 (Satış Fiyatı): 2.0187519
- x3 (Üretim Maliyeti): -0.4967157
- x42 (Hedefli Pazarlama): -0.7068003
- x43 (Yaratıcı Pazarlama): -2.8420522

Bu değerlere göre kurulan Ridge regresyon denklemi şöyledir:

$$\hat{y} = 1.67 + 8.5456871x_1 + 2.0187519x_2 - 0.4967157x_3 - 0.7068003 \cdot I(x_4 = 2) - 2.8420522 \cdot I(x_4 = 3)$$

Bu model, satış hacmi, satış fiyatı ve üretim maliyeti gibi değişkenleri düzenlenmiş şekilde değerlendirerek çoklu bağlantıdan kaynaklanan sapmaları azaltır ve tahminlerin güvenilirliğini artırır. **Ancak** bizim regresyon modelinde çoklu bağlantı sorunu olmadığından bu ridge regresyon modeli kullanılmaz.